


extractor.py

Usada para extrair valores de ângulos da conformação de aminoácidos, duma lista de proteínas.



Descrição: Decompõe as cadeias de uma proteína em aminoácidos. Registrando em ficheiros separados por aminoácido, informação sobre os ângulos diédricos que definem cada conformação. Para cada aminoácido regista ocorrências de phi, psi, dC_CA, dN_CA, dN_C, dP_plane, ang_N_CA_C, chi1, chi2, chi3, chi4 e tempFactor. A mesma informação é registada para a ocorrência de pares de aminoácidos. Para janelas de três aminoácidos específicos é registado apenas o phi, psi de cada um mais os omega entre eles.

Os ficheiros PDB são descarregados via **BioPython** e guardados em python/proteinData/. Estruturas de ácidos nucleicos (DNA/RNA) são excluídas via campo header. Resíduos sem átomos N, C_α ou C' são ignorados. Ângulos com ligações > 6.5 Å são marcados como NaN.

Input: data/pdb1A.tsv — lista de 607 identificadores PDB

Output: Três tipos de ficheiros em python/aminoData/

Por aminoácido: aminoData/<AMINO>.csv 12 colunas
phi, psi, dC_CA, dN_CA, dN_C, dP_plane, ang_N_CA_C, tempFactor, chi1, chi2, chi3, chi4

Por par de aminoácidos: aminoData/<AA1><AA2>.csv 16 colunas
phi1, psi1, dC_CA1, dN_CA1, dN_C1, dP_plane1, ang_N_CA_C1, tempFactor_max, phi2, psi2, omega2, dC_CA2, dN_CA2, dN_C2, dP_plane2, ang_N_CA_C2

Por três aminoácidos seguidos: aminoData/rotamer_w3.csv 12 colunas
resName1, resName2, resName3, phi1, psi1, phi2, psi2, omega2, phi3, psi3, omega3, tempFactor_max

Cada proteína é carregada como um objecto Bio.PDB.Structure.

O ângulo diédrico é calculado através do produto vectorial dos planos definidos por quatro átomos:

$$\varphi_{AB} = \arccos\left(\frac{\mathbf{U}_A \cdot \mathbf{U}_B}{|\mathbf{U}_A||\mathbf{U}_B|}\right) = \arcsin\left(\frac{|\mathbf{U}_A \times \mathbf{U}_B|}{|\mathbf{U}_A||\mathbf{U}_B|}\right)$$

$$\text{onde } \mathbf{U}_A = (\mathbf{A}_2 - \mathbf{A}_1) \times (\mathbf{A}_3 - \mathbf{A}_1), \quad \mathbf{U}_B = (\mathbf{B}_2 - \mathbf{B}_1) \times (\mathbf{B}_3 - \mathbf{B}_1)$$



Ligação	Média (Å)	σ (Å)	Ref. (Å)
C'–C _α (dC_CA)	1.5227	0.0145	1.52
N–C _α (dN_CA)	1.4573	0.0142	1.46
C'–N (dP_plane)	1.3364	0.1304	1.33
ω trans (ω > 150)	> 99%	—	—

Valores observados em 607 estruturas PDB (conjunto pdb1A).

analysis.py

circ_stat.py

Calcula potenciais estatísticos 2D por pares de ângulos diédrais, via KDE de von Mises, e os gradientes correspondentes para uso em dinâmica de sistemas de corpos rígidos.



Descrição: Carrega os ficheiros CSV de cada aminoácido gerados pela Fase 1, ajusta distribuições de von Mises 2D por estimação de máxima verossimilhança, e calcula o potencial estatístico $E = -\log p$ e os gradientes $(\partial E / \partial \alpha_1, \partial E / \partial \alpha_2)$ para cada par de ângulos diédrais. Os mapas são guardados em formato .npz.

Input: python/aminoData/<AMINO>.csv (saída de extractor.py)

Output: python/contData/Mises<AMINO>180.npz — 20 ficheiros (um por aminoácido)

Estimação de parâmetros von Mises (circ_stat.py — circ_vmpar):

$$\hat{\kappa} = \begin{cases} 2\bar{R} + \bar{R}^3 + \frac{5}{6}\bar{R}^5 & \bar{R} < 0.53 \\ -0.4 + 1.39\bar{R} + 0.43(1 - \bar{R})^{-1} & 0.53 \leq \bar{R} < 0.85 \\ (\bar{R}^3 - 4\bar{R}^2 + 3\bar{R})^{-1} & \bar{R} \geq 0.85 \end{cases} \quad \bar{R} = \frac{1}{n} \left| \sum_{k=1}^n e^{i\alpha_k} \right|$$

KDE 2D von Mises (circ_stat.py — circ_vmpdf2):

$$p(\alpha_1, \alpha_2) = \frac{1}{4\pi^2 n I_0(\kappa_1) I_0(\kappa_2)} \sum_{k=1}^n e^{\kappa_1 \cos(\alpha_1 - \alpha_{1k})} e^{\kappa_2 \cos(\alpha_2 - \alpha_{2k})} = \frac{\mathbf{A} \mathbf{B}^\top}{C}$$

Factorização matricial: $\mathbf{A}_{ij} = e^{\kappa_1 \cos(\phi_i - \alpha_{1j})}$, $\mathbf{B}_{ij} = e^{\kappa_2 \cos(\psi_i - \alpha_{2j})}$ — reduz $O(nM^2)$ para $O(nM)$.

Potencial e gradientes (analysis.py): $E = -\log p$, $F_{\alpha_1} = -\partial E / \partial \alpha_1$, $F_{\alpha_2} = -\partial E / \partial \alpha_2$

Gradientes por diferenças centrais (np.gradient) — equivalente ao imgradientxy do MATLAB.

Pares calculados por aminoácido:

Cam.	Par	Aminoácidos	Descrição
1	φ - ψ	todos (20)	Ramachandran backbone
2	φ - χ_1	c/ cadeia lateral (18)	acoplamento backbone-rotâmero
3	ψ - χ_1	c/ cadeia lateral (18)	acoplamento backbone-rotâmero
4	χ_1 - χ_2	15 aminoácidos	rotâmero-rotâmero
5	χ_2 - χ_3	ARG, GLN, GLU, LYS, MET	rotâmero-rotâmero
6	χ_3 - χ_4	ARG, LYS	rotâmero-rotâmero

Conteúdo de cada ficheiro .npz:

Para cada par de ângulos k (até 6 por aminoácido):	
E_k	Potencial $-\log p$, forma (180×180) , 2/célula
Gx_k	Gradiente $\partial E / \partial \alpha_2$, forma (180×180)
Gy_k	Gradiente $\partial E / \partial \alpha_1$, forma (180×180)
kappa_k	Concentrações $[\kappa_1, \kappa_2]$
n_k	Nº amostras; pair_k: nome do par